

Ensamblado Genómico con Grafos de De Bruijn Apareados

Desafíos Estructurales y Punto Crítico en *Candidatus Carsonella ruddii*

Autores: Ignacio Berney, Rundong He

1. Introducción Teórica y Marco Conceptual

1.1. Contexto Biológico y Desafío Bioinformático

El objeto de estudio es la bacteria *Candidatus Carsonella ruddii*, reconocida por poseer uno de los genomas bacterianos más reducidos observados en la naturaleza, con una longitud total de 173,904 pares de bases.

Investigando las propiedades estructurales de su ADN, se observa un marcado sesgo hacia los nucleótidos de adenina (A) y timina (T), alcanzando aproximadamente un 85,38 % de composición AT. Esta baja entropía en la composición nucleotídica genera una elevada concentración de repeticiones locales en comparación con otros genomas procariotas, constituyendo un desafío computacional severo para los algoritmos convencionales de ensamblado genómico basados en grafos de De Bruijn.

1.2. Grafo de De Bruijn Apareado ((k, d) -meros)

Para mitigar las ambigüedades topológicas inducidas por repeticiones dispersas en el genoma, se emplean lecturas pareadas formalizadas como (k, d) -meros.

- **Definición de (k, d) -mero:** Consiste en un par ordenado de subcadenas (s_1, s_2) , ambas de longitud uniforme k , separadas por una distancia o brecha (*gap*) fija de longitud d en la secuencia original.
- **Estructura del Grafo Apareado:** Los vértices del grafo representan pares de $(k-1)$ -meros de la forma $(s_1[0..k-2], s_2[0..k-2])$, mientras que las aristas orientadas representan los pares (k, d) -meros completos extraídos del genoma.
- **Mecanismo de Desambiguación:** La información contextual provista por la segunda ventana s_2 (ubicada a una distancia física fija d) funciona como un ancla de desambiguación. Si la primera ventana s_1 incide en una región repetida, la posición coincidente de s_2 en una región única distante restringe la ramificación del grafo, reduciendo el número de recorridos posibles a un único camino euleriano válido.

1.3. Restricciones Matemáticas del Modelo

Para poder extraer un par (k, d) -mero de una secuencia dada, se requiere abarcar una ventana mínima de $2k + d$ nucleótidos. Dado que cada par sucesivo extraído avanza un único nucleótido en el flujo de lectura, cubrir una brecha de tamaño d exige necesariamente la extracción de pares adicionales consecutivos.

Por ende, además de la restricción inicial, se precisa disponer de d posiciones remanentes en la secuencia para que el algoritmo progrese y deduzca con certeza los d caracteres intermedios. Se impone así la restricción acotada:

$$2k + 2d \leq \text{Longitud del Genoma} \quad (1)$$

2. Metodología Experimental

Se diseñó una batería de experimentos sistemáticos con el fin de caracterizar el comportamiento del ensamblador frente a regímenes extremos de los parámetros k y d . Debido al volumen de comparaciones de cadenas y los límites de memoria física, valores superiores a $k \approx 5500$ resultaron computacionalmente inviables. El análisis empírico reveló un **punto crítico en $k = 13$** , a partir del cual se realizaron evaluaciones exhaustivas de tasa de éxito en función de la brecha d , explorando regiones periféricas, distancias intermedias y tramos aleatorios de la secuencia.

Listing 1: Rutina de barrido para evaluación de ensamblado en $k = 14$ con saltos de $d = 1000$.

```
load_cache();
for (int k = 14; k <= 14; k += 1) {
    for (int d = 0; d <= 86000; d += 1000) {
        test(k, d);
    }
}
save_cache();
cout << succeed_cnt << " / " << total << endl;
```

3. Resultados y Análisis

3.1. Inviabilidad del Grafo Clásico para $k \leq 12$

Se demostró empírica y teóricamente que el algoritmo de ensamblado es incapaz de reconstruir unívocamente el genoma para valores de $k \leq 12$, registrando una tasa de éxito efectiva del **0 %**. El sesgo composicional del 85,38 % de AT deriva en más de 21,500 k -meros redundantes, multiplicando los caminos alternativos y anulando el criterio de unicidad del recorrido euleriano.

3.2. Punto de Transición de Fase Crítica ($k = 13$)

La longitud $k = 13$ establece el límite exacto a partir del cual el modelo apareado logra resolver los primeros ensamblados completos. Para distancias d reducidas la ambigüedad persiste; sin embargo, al aproximarse al límite teórico superior ($d \approx 86,939$), la tasa de éxito alcanza aproximadamente un **33 %**. El par resolutivo más compacto registrado fue:

$$(k = 13, d = 59,000)$$

3.3. Eficiencia y Colapso de la Distancia Mínima Requerida

A medida que se incrementa el tamaño del k -mero, la fracción de subcadenas únicas en el genoma crece con rapidez: para $k \geq 16$, más del 94,8 % de los k -meros resultan únicos. Como consecuencia directa, la distancia física $d_{\min}$ necesaria para garantizar la convergencia colapsa exponencialmente, requiriéndose únicamente $d \geq 5$ nucleótidos.

4. Desafíos Encontrados

- **Articulación Interdisciplinaria (Computación y Biología):** Integrar los fundamentos biológicos de la estructura genómica con las propiedades formales de los grafos orientados y la combinatoria de secuencias constituyó el principal desafío conceptual del trabajo.




Figura 1: Relación entre la unicidad de k-meros y la tasa de éxito de reconstrucción, evidenciando la zona inviable y la transición crítica.




Figura 2: Evolución de la tasa de reconstrucción única según el rango de k-mero.

Rango de k -mero	Unicidad de k -meros	Tasa de Éxito	Distancia Mínima ($d_{\min}$)
$k \leq 12$	$< 82,0 \%$	0 %	Inviabile (no reconstruye)
$k = 13$	$\approx 86,2 \%$	15 % – 33 %	59,000
$k = 14$	$\approx 89,5 \%$	72 %	50
$k = 15$	$\approx 92,1 \%$	94 %	7
$k \geq 16$	$> 94,8 \%$	100 %	≤ 5

Tabla 1: Resumen comparativo del desempeño de reconstrucción según el tamaño de k -mero.




Figura 3: Caída drástica de la distancia mínima requerida ($d_{\min}$) al aumentar el tamaño de k -mero.

- **Metodología de Investigación Empírica:** El diseño autónomo de protocolos experimentales, la automatización de miles de ejecuciones de prueba y la posterior síntesis analítica permitieron fundamentar de forma rigurosa las conclusiones obtenidas.